Compte rendu - Optimisation d'un réseau de neurones pour la classification de textes

1. Objectif

L'objectif de ce travail était d'étudier le fonctionnement d'un réseau de neurones destiné à classer automatiquement des textes selon leur thématique. Le modèle utilise plusieurs couches de neurones denses et doit reconnaître cinq catégories : astronomie, cuisine, peinture, football et Seconde Guerre mondiale.

Différentes expérimentations ont été réalisées afin de comprendre l'influence des hyperparamètres sur les performances du modèle, d'identifier les risques de sur-apprentissage et d'évaluer les possibilités de réduction de sa taille.

2. Influence des hyperparamètres

Taux d'apprentissage

Quatre taux d'apprentissage ont été testés : 0,0001, 0,001, 0,01 et 0,1.

Les taux de 0,001 et 0,01 ont obtenu les meilleurs résultats, avec une précision de validation de 95 %. Un taux trop faible (0,0001) a limité l'apprentissage à 47,5 %, tandis qu'un taux trop élevé (0,1) a donné une précision de 82,5 %.

Ces résultats montrent qu'un taux d'apprentissage mal adapté peut ralentir l'apprentissage ou dégrader les performances.

Taille du réseau

Plusieurs architectures ont également été comparées.

Architecture	Précision de validation	Paramètres
4 + 2 neurones	22,5 %	8 029
16 + 8 neurones	67,5 %	32 197
64 + 32 neurones	95 %	130 309
256 + 128 neurones	95 %	545 797

L'augmentation du nombre de neurones améliore les performances jusqu'à un certain point. Cependant, le réseau de 256 + 128 neurones n'apporte aucun gain de précision par rapport à celui de 64 + 32, malgré un nombre de paramètres plus de quatre fois supérieur.

3. Surapprentissage et fiabilité des résultats

Deux méthodes ont été expérimentées pour limiter le surapprentissage : le **dropout**, qui désactive aléatoirement certains neurones pendant l'entraînement, et l'**arrêt précoce**, qui interrompt l'apprentissage lorsque la perte de validation ne s'améliore plus suffisamment.

Dans l'expérience contrôlée, la perte finale de validation est passée de 0,207 sans remède à 0,163 avec dropout et 0,164 avec arrêt précoce. La précision est toutefois restée à 95 % dans les trois cas.

Les essais réalisés avec différentes graines aléatoires ont également montré des variations de précision entre 92,5 % et 95 %. Cela souligne qu'une petite différence entre deux résultats peut simplement provenir du hasard. Avec seulement 40 textes de validation dans certaines expériences, il faut donc rester prudent dans l'interprétation des écarts.

4. Allègement du modèle

Deux approches ont été étudiées pour réduire le coût du modèle.

La première est la **quantification**, qui permet de réduire la précision de stockage des poids. Le modèle est passé d'environ 589 Ko à 132 Ko, soit une réduction de taille d'environ 77,6 %. La précision du modèle quantifié reste à confirmer avec une évaluation adaptée sur le jeu de test.

La seconde approche consiste à utiliser directement un réseau plus petit. Une architecture de 8 + 4 neurones ne comporte que 16 074 paramètres, mais sa précision de validation chute à 44,9 %. La réduction de taille entraîne donc ici une perte de performance trop importante.

5. Conclusion

Ces expériences montrent qu'un réseau plus grand n'est pas nécessairement plus performant. Le choix des hyperparamètres doit tenir compte de la précision obtenue, du nombre de paramètres et du coût de calcul.

Le réseau de **64 + 32 neurones**, avec un taux d'apprentissage de **0,001**, représente le meilleur compromis parmi les configurations testées. La quantification semble également intéressante pour réduire les besoins de stockage, à condition de vérifier qu'elle préserve suffisamment la précision du modèle.

Enfin, les variations liées au hasard et à la taille limitée du jeu de validation rappellent l'importance de répéter les expériences avant de conclure qu'une amélioration est réellement significative.